

Name: _____

Nicht bestanden: ☐

Vorname: _____

Matrikelnummer: _____

Endnote: _____

Studierende der Fakultät Agrarwissenschaften und Landschaftsarchitektur (AuL)

Probeklausur Bio Data Science

für Pflichtmodule

im 1. & 2. Semester B.Sc./M.Sc.

Prüfer: Prof. Dr. Jochen Kruppa-Scheetz
Fakultät für Agrarwissenschaften und Landschaftsarchitektur
j.kruppa@hs-osnabrueck.de

Erlaubte Hilfsmittel

- Normaler Taschenrechner ohne Möglichkeit der Kommunikation mit anderen Geräten! Ausdrücklich kein Handy!
- Eine DIN A4-Seite als beidseitig, selbstgeschriebene, handschriftliche Formelsammlung. Keine digitalen Ausdrucke!
- *You can answer the questions in English without any consequences.*

Formalia

- Um eine faire Korrektur zu gewährleisten,
 - **ist die Verwendung eines roten Farbstiftes ist nicht gestattet. Es ist die Korrekturfarbe.**
 - schreiben Sie bitte groß genug und leserlich mit einem dokumentenechten Stift (kein Bleistift).
 - nicht zwischen die Fragezeilen schreiben! Die Nutzung des Aufgabentextes für Antworten führt zu Punktabzug.
 - erstellen Sie Abbildungen in angemessener Größe und achten Sie auf eine klare Erkennbarkeit. Nutzen Sie bei Platzmangel bitte ein separates Blatt.
- Verstöße können mit einem Punktabzug geahndet werden: **□ (-2 Punkte)**

Ergebnis der Klausur

_____ von 20 Punkten sind aus dem Multiple Choice Teil erreicht.
_____ von 72 Punkten sind aus dem Rechen- und Textteil erreicht.
_____ von 92 Punkten in Summe.

Es wird folgender Notenschlüssel angewendet.

Punkte	Note
88.0 - 92.0	1,0
83.5 - 87.5	1,3
78.5 - 83.0	1,7
74.0 - 78.0	2,0
69.5 - 73.5	2,3
65.0 - 69.0	2,7
60.5 - 64.5	3,0
55.5 - 60.0	3,3
51.0 - 55.0	3,7
46.0 - 50.5	4,0

Es ergibt sich eine Endnote von _____.

Multiple Choice Aufgaben

- Pro Multiple Choice Frage ist *genau* eine Antwort richtig.
- **Übertragen Sie Ihre Kreuze in die Tabelle auf dieser Seite.**
- Es werden nur Antworten berücksichtigt, die in dieser Tabelle angekreuzt sind!

	A	B	C	D	E	✓
1 Aufgabe						
2 Aufgabe						
3 Aufgabe						
4 Aufgabe						
5 Aufgabe						
6 Aufgabe						
7 Aufgabe						
8 Aufgabe						
9 Aufgabe						
10 Aufgabe						

- Es sind ____ von 20 Punkten erreicht worden.

Rechen- und Textaufgaben

- Die Tabelle wird vom Dozenten ausgefüllt.

Aufgabe	11	12	13	14	15	16	Hausarbeit
Punkte	8	10	10	12	10	12	10

- Es sind ____ von 72 Punkten erreicht worden.

Bitte ankreuzen, wenn zutreffend:

- ☐ **Ich habe eine Hausarbeit abgegeben.** Bitte die Punkte entsprechend berücksichtigen.
- ☐ **Ich habe eine Präsentation gehalten.** Bitte die Punkte entsprechend berücksichtigen.

1 Aufgabe

(2 Punkte)

Nach einem Feldexperiment wollen Sie zwei Gruppen mit einem Welch t-Test vergleichen. Welche Aussage ist auch für den Student t-Test richtig?

- ☐ A Der t-Test testet generell zu einem erhöhten α -Niveau von 20%.
- ☐ B Der t-Test vergleicht die Mittelwerte von zwei Gruppen unter der strikten Annahme von Varianzhomogenität. Sollte keine Varianzhomogenität vorliegen, so gibt es keine Möglichkeit den t-Test in einer Variante anzuwenden.
- ☐ C Der t-Test berechnet die Differenz von zwei Mittelwerten als Effekt und gibt eine Entscheidung, ob sich die beiden Mittelwerte *jeweils* von Null unterscheiden.
- ☐ D Der t-Test vergleicht die Mittelwerte von zwei Gruppen.
- ☐ E Der t-Test vergleicht zwei oder mehr Gruppen indem die Mittelwerte miteinander verglichen werden.

2 Aufgabe

(2 Punkte)

Die Varianz ist eine bedeutende deskriptive Statistik für die Analyse von Daten. Wie müssen Sie vorgehen um die Varianz zu berechnen?

- ☐ A Wir berechnen erst den Mittelwert und dann die quadratischen Abstände zu dem Mittelwert. Diese quadratischen Abstände summieren wir auf und teilen am Ende durch die Fallzahl ($n - 1$). Als letzten Schritt ziehen wir die quadratische Wurzel.
- ☐ B Den Mittelwert berechnen und die Abstände quadrieren. Die Summe mit der Fallzahl ($n - 1$) multiplizieren.
- ☐ C Als erstes berechnen wir den Mittelwert. Dann bilden wir die Summe der quadratischen Abstände zu dem Mittelwert. Abschließend teilen wir durch die Fallzahl ($n - 1$).
- ☐ D Den Mittelwert berechnen, dann die absoluten Abstände zum Mittelwert aufsummieren. Die Fallzahl ($n - 1$) entsprechend gewichten.
- ☐ E Den Median berechnen, dann die quadratischen Abstände zum Median aufsummieren, dann die Wurzel ziehen. Am Ende durch die Fallzahl ($n - 1$) teilen

3 Aufgabe

(2 Punkte)

Das Signifikanzniveau α wird auch Fehler 1. Art genannt und liegt bei 5%. Warum wurde der Grenzwert von 5% als Signifikanzschwelle gewählt?

- ☐ A Da Wissenschaftler eine Schwelle für die statistische Testentscheidung benötigen wurde α in einer großen Konferenz 1945 gewählt. Damit ist $\alpha = 5\%$ eine Kulturkonstante mit einem Rank einer Naturkonstante.
- ☐ B Der Wert ergab sich aus einer Auswertung von 1042 wissenschaftlichen Veröffentlichungen zwischen 1914 und 1948. Der Wert 5% wurde in 28% der Veröffentlichungen genutzt. Daher legte man sich auf diese Zahl fest.
- ☐ C Als Kulturkonstante hat $\alpha = 5\%$ den Rang einer Naturkonstante und wurde nach langer Diskussion in der UN im Jahre 1983 festgesetzt. Damals auch schon mit der Zustimmung der UdSSR.
- ☐ D In der Wissenschaft gibt es neben der Naturkonstante, die sich aus der Beobachtung der Welt ergibt, noch die Kulturkonstante, die von einer Gruppe Menschen selbstgewählt wird. Dabei ist $\alpha = 5\%$ eine Kulturkonstante und wurde somit eher zufällig gewählt.
- ☐ E Im Rahmen eines langen Disputs zwischen Neyman und Fischer wurde $\alpha = 5\%$ festgelegt. Leider werden die Randbedingungen und Voraussetzungen an statistische Modelle heute immer wieder ignoriert.

4 Aufgabe

(2 Punkte)

Der Boxplot stellt folgende statistische Maßzahlen in einer Abbildung dar. Damit gehört der Boxplot zu einem der am meisten genutzten statistischen Verfahren zur Visualisierung von Daten.

- ☐ A Der Boxplot stellt die Mittelwerte und die Varianz dar.
- ☐ B Der Boxplot stellt die Mittelwerte und die Standardabweichung dar.
- ☐ C Den Mittelwert und die Varianz.
- ☐ D Der Boxplot stellt den Median und die Streuung dar.
- ☐ E Durch die Abbildung des Boxplot erhalten wir die Informationen über den Median und die Quartile.

5 Aufgabe

(2 Punkte)

Aus einem Feldversuch ergibt sich die Notwendigkeit der Berechnung einer einfaktoriellen ANOVA. Es ergibt sich ein $\eta^2 = 0.12$. Welche Aussage ist richtig?

- ☐ A Das η^2 beschreibt den Anteil der Varianz, der von den Behandlungsbedingungen nicht erklärt wird. Somit der Rest an nicht erklärbarer Varianz.
- ☐ B Das η^2 ist ein Wert für die Güte der ANOVA. Je kleiner desto besser. Ein η^2 von 0 bedeutet ein perfektes Modell mit keiner Abweichung. Die Varianz ist null.
- ☐ C Die Berechnung von η^2 ist ein Wert für die Interaktion in der einfaktoriellen ANOVA.
- ☐ D Das η^2 beschreibt den Anteil der Varianz, der von den Behandlungsbedingungen erklärt wird.
- ☐ E Das η^2 beschreibt den Anteil der globalen Varianz, der von den Umweltbedingungen erklärt wird.

6 Aufgabe

(2 Punkte)

In Ihrer Forschungsarbeit wollen Sie eine Aussage über ein untersuchtes Individuum treffen. Dazu nutzen Sie einen statistischen Test. Erhalten Sie eine valide Aussage aus einem statistischen Test?

- ☐ A ☐ Ja, ein untersuchtes Individuum können wir mit einem statistischen Test auswerten. Wir erhalten dann eine Aussage zum Individuum.
- ☐ B ☐ Ja, wir können ein untersuchtes Individuum nicht mit einem t-Test auswerten. Wir erhalten keine Aussage zum Individuum. Wir können aber den Effekt als Quelle der Relevanz nutzen.
- ☐ C ☐ Ja, wir erhalten eine einfache Aussage. Wir müssen daher das Individuum im Kontext der Population adjustieren.
- ☐ D ☐ Weder eine Aussage über die Population noch über das Individuum ist mit einem statistischen Test möglich. Wir erhalten eine Aussage über ein Experiment.
- ☐ E ☐ Nein, es ist nicht möglich ein untersuchtes Individuum mit einem statistischen Test auszuwerten. Wir erhalten dann leider keine Aussage zum Individuum.

7 Aufgabe

(2 Punkte)

In Ihrer Abschlussarbeit müssen Sie für die statistischen Tests im Anhang Ihrer Arbeit die Hypothesen H formulieren. Welche Aussage über Hypothesen H ist richtig

- ☐ A ☐ Es gibt ein Hypothesenset bestehend aus k Hypothesen. Meistens wird die Nullhypothese H_0 und die Alternativhypothese H_A verwendet. Wegen des Falsifikationsprinzips ist es wichtig, die bekannte falsche und unbekannte richtige Hypothese mit in das Set zu nehmen.
- ☐ B ☐ Mit der Nullhypothese H_0 und der Alternativhypothese H_A oder H_1 gibt es zwei Hypothesen.
- ☐ C ☐ Es gibt - bedingt durch das das Falsifikationsprinzip - ein Set von k Nullhypothesen, die iterative gegen $k - 1$ Alternativhypothesen getestet werden.
- ☐ D ☐ Mit der Nullhypothese H_A und der Alternativhypothese H_0 gibt es zwei Hypothesen, die aber selten genutzt werden.
- ☐ E ☐ Es gibt ein statistisches Hypothesenpaar mit der Hypothese für und gegen die wissenschaftliche Fragestellung. Die Hypothesen werden H_{pro} und H_{contra} bezeichnet.

8 Aufgabe

(2 Punkte)


Geben ist $Pr(D|H_0)$ als mathematischer Ausdruck, welche Aussage ist richtig?

- ☐ A ☐ $Pr(D|H_0)$ ist die Wahrscheinlichkeit die Daten D zu beobachten, wenn die Nullhypothese wahr ist.
- ☐ B ☐ Die Wahrscheinlichkeit der Daten unter der Nullhypothese in der Grundgesamtheit.
- ☐ C ☐ $Pr(D|H_0)$ ist die Wahrscheinlichkeit nicht die Daten D zu beobachten sondern die Nullhypothese, wenn diese wahr ist.
- ☐ D ☐ Die Inverse der Wahrscheinlichkeit unter der die Nullhypothese nicht mehr die Alternativhypothese überdeckt.
- ☐ E ☐ $Pr(D|H_0)$ stellt die Wahrscheinlichkeit die Teststatistik T zu beobachten dar, wenn die Nullhypothese falsch ist.

9 Aufgabe

(2 Punkte)

Die Normalverteilung wird durch den Mittelwert und die Standardabweichung definiert. Welche Aussage im Bezug zur Standardabweichung in einer Normalverteilung ist richtig?



- ☐ A ☐ Die Fläche unter der Kurve entspricht dem Signifikanzniveau α von 5%. Damit ist die Standardabweichung σ gleich 1 in der obigen Abbildung.
- ☐ B ☐ Dargestellt ist keine Standardnormalverteilung.
- ☐ C ☐ Es liegen 95% der Beobachtungen zwischen $\bar{y} \pm 2\sigma$. Angezeigt durch die Fläche zwischen -2σ und 2σ in der obigen Verteilung.
- ☐ D ☐ Die Fläche links von -2σ ist der p-Wert mit $Pr(D|H_0)$ in der obigen Abbildung.
- ☐ E ☐ Die Fläche unter der Kurve ist 1, wenn die Nullhypothese falsch ist. Wenn die Nullhypothese gilt, dann ist die Fläche $1 - \alpha$. Somit ergibt sich auch eine Standardabweichung σ mit α gleich 0.05 in beiden Fällen.

10 Aufgabe

(2 Punkte)

Roland Fischer entwickelte Anfang des letzten Jahrhunderts als Grundlage für das experimentelle Design in der Statistik die Randomisierung. Warum ist die Randomisierung für die Entscheidung anhand einer statistischen Auswertung so wichtig?

- A** ☐ Randomisierung erlaubt erst die Varianzen zu schätzen. Ohne eine Randomisierung ist die Berechnung von Mittelwerten und Varianzen nicht möglich. Dadurch lässt sich erst ein Experiment auswerten.
- B** ☐ Randomisierung sorgt für Strukturgleichheit und erlaubt erst von der Stichprobe auf die Grundgesamtheit zurückzuschließen.
- C** ☐ Randomisierung bringt starke Unstrukturiertheit in das Experiment und erlaubt erst von der Stichprobe auf die Grundgesamtheit zurückzuschließen.
- D** ☐ Randomisierung ist die direkte Folge von Strukturgleichheit. Die Strukturgleichheit erlaubt es erst von der Stichprobe auf die Grundgesamtheit zurückzuschließen.
- E** ☐ Strukturgleichheit ist durch Randomisierung gegeben. Leider hilft die Randomisierung noch nicht um von der Stichprobe auf die Grundgesamtheit zu schließen. Deshalb wurde das Falsifikationsprinzip entwickelt.

11 Aufgabe

(8 Punkte)

Geben Sie grundsätzlich Formeln und Rechenweg zur Lösung der Teilaufgaben mit an!

Barplots sind bedeutend in der Darstellung von wissenschaftlichen Ergebnissen. Leider hat sich Alex nicht gemerkt, welche statistischen Maßzahlen für einen Barplot erhoben werden müssen. Besser wäre was anderes gewesen. Am Ende dann doch besser Starcraft. Wunderbar. Eine echte Ablenkung für Alex. Das ist in soweit doof, da nach seiner Betreuerin nun Barplots aus seinen Daten gebaut werden sollen, bevor es mit dem statistischen Testen weitergeht. Na dann mal los. Alex schafft sich die nötige Stimmung. Wenn Abba ertönt, dann sucht die Katze schleunigst Schutz unter dem Sofa. Alex schüttelt den Kopf. Die Behandlung für Lauch waren verschiedene Bewässerungstypen (*low*, *mid* und *high*). Erfasst wurde von Alex als Messwert (*Y*) *Ertrag*. Alex hat dann *yield* in seiner Exceldatei eingetragen. Aber auch irgendwie egal. Um zu Laufen geht Alex dann später nochmal raus. Echte Entspannung.

treatment	yield
high	36.9
mid	41.3
low	37.5
high	41.4
high	17.4
low	27.4
low	11.3
mid	38.4
high	34.4
mid	29.6
mid	45.3

Leider kennt sich Alex mit der Erstellung von Barplots nicht aus. Deshalb braucht er bei der Visualisierung Ihre Hilfe!

1. Formulieren Sie die wissenschaftliche Fragestellung! **(1 Punkt)**
2. Zeichnen Sie in einer Abbildung die Barplots für die Behandlung von Lauch! Beschriften Sie die Achsen entsprechend! **(4 Punkte)**
3. Beschriften Sie einen Barplot mit den gängigen statistischen Maßzahlen! **(2 Punkte)**
4. Wenn Alex einen Effekt zwischen den Behandlungen von Lauch erwarten würde, wie sehen dann die Barplots aus? Antworten Sie mit einer Skizze der Barplots! **(1 Punkt)**

12 Aufgabe

(10 Punkte)

Geben Sie grundsätzlich Formeln und Rechenweg zur Lösung der Teilaufgaben mit an!

Wenn es nach Jessica ginge, wäre sie schon längst fertig mit ihrem Projektbericht. Geht es aber nicht. 'Hm...', Schokobons und David Bowie. Das ist und bleibt die beste Kombination zum Nachdenken für Jessica. In ihrem Projektbericht hatte sie ein Stallexperiment in der Uckermark durchgeführt. Nach der Meinung ihrer Betreuerin sieht das jedoch etwas anders aus. Jetzt soll sie doch noch eine explorative Datenanalyse für den Zusammenhang zwischen durchschnittlichen Bewegungsscore [Movement/h] und Fettgehalt [%/kg] in Lamas durchführen. Wie nervig! Eine echte Herausforderung für sie war schon immer der Mangel gewesen. Ein leidiges Lied. Da zwei kontinuierliche Variablen vorliegen, geht die explorative Datenanalyse leider nicht mit Boxplots oder Barplots. Dann was anderes. Das Verrückte ist, dass die Hündin Herr der Ringe wirklich liebt. Das ist Jessica sehr recht, denn sie braucht Entspannung.

Durchschnittlichen Bewegungsscore [Movement/h]	Fettgehalt [%/kg]
5.5	3.1
12.0	12.3
2.5	-0.7
9.5	7.0
5.0	5.5
0.5	-0.5
3.5	6.4
9.0	8.4

Leider kennt sich Jessica mit der Erstellung einer explorativen Datenanalyse für kontinuierliche Daten überhaupt nicht aus. Deshalb braucht sie bei der Erstellung Ihre Hilfe!

1. Erstellen Sie eine Visualisierung für die Datentabelle. Beschriften Sie die Achsen entsprechend! **(4 Punkte)**
2. Schätzen Sie eine Grade durch die Punkte! **(1 Punkt)**
3. Beschriften Sie die Grade mit den gängigen statistischen Maßzahlen! Geben Sie die numerischen Zahlenwerte mit an! **(3 Punkte)**
4. Wenn *ein* Effekt von x auf y vorhanden wäre, wie würde die Grade verlaufen und welche Werte würden die statistischen Maßzahlen annehmen? **(2 Punkt)**

13 Aufgabe

(10 Punkte)

'So, was haben wir gemacht? Wir haben einen t-test für den Vergleich der Mittelwerte gerechnet.', meint Steffen. Yuki schaut fragend. 'Hatten wir nicht alles zu einer Kontrolle verglichen? Das war doch so!', ruft Yuki laut aus. 'Wir haben doch als Messwert *Trockengewicht nach Düngergabe* erhoben.', stellt Steffen fest. Jetzt haben beide das Problem, die möglichen 95% Konfidenzintervalle zu interpretieren.

Leider kennen sich Steffen und Yuki mit der Visualisierung des 95% Konfidenzintervall überhaupt nicht aus.

1. Beschriften Sie die untenstehende Abbildung mit der Signifikanzschwelle! Begründen Sie Ihre Antwort! **(2 Punkte)**
2. Ergänzen Sie eine *in den Kontext passende* Relevanzschwelle! Begründen Sie Ihre Antwort! **(2 Punkte)**
3. Skizzieren Sie in die untenstehende Abbildung sechs einzelne Konfidenzintervalle (a-f) mit den jeweiligen Eigenschaften! **(6 Punkte)**
 - (a) Ein signifikantes, nicht relevantes 95% Konfidenzintervall
 - (b) Ein 95% Konfidenzintervall mit höherer Varianz s_p in der Stichprobe als der Rest der 95% Konfidenzintervalle
 - (c) Ein 95% Konfidenzintervall mit niedriger Varianz s_p in der Stichprobe als der Rest 95% der Konfidenzintervalle
 - (d) Ein nicht signifikantes, nicht relevantes 95% Konfidenzintervall
 - (e) Ein signifikantes, relevantes 95% Konfidenzintervall
 - (f) Ein signifikantes, relevantes 99% Konfidenzintervall.



14 Aufgabe

(12 Punkte)

Geben Sie grundsätzlich Formeln und Rechenweg zur Lösung der Teilaufgaben mit an!

'Als erstes bauen wir uns aus unsere Daten die ANOVA Tabelle dann sehen wir schon, ob unser Gruppenvergleich in der ANOVA signifikant ist.', Jonas schaut Mark fragend an und hofft auf eine positive Regung im Gesicht. Wird aber enttäuscht. Mark schmeißt sich noch ein paar Marzipankugeln in den Rachen. Beide tun sich sehr schwer mit der einfaktoriellen ANOVA. Nun möchte erstmal ihre Betreuung der Arbeit eine ANOVA Tabelle sehen. Was immer da auch drin zu erkennen sein mag. Beide waren in der Uckermark um einen Versuch in einer Klimakammer mit Lauch durchzuführen. Dabei ging es herauszufinden, ob es einen Zusammenhang zwischen der Behandlung Bewässerungstypen (*ctrl*, *low*, *mid* und *high*) und dem Messwert Proteingehalt [g/kg] gibt. Später wollen die beiden dann noch raus um zu Reiten.

Leider kennen sich Jonas und Mark mit Berechnung einer einfaktoriellen ANOVA überhaupt nicht aus. Deshalb brauchen beide bei der Erstellung Ihre Hilfe!

1. Formulieren Sie die wissenschaftliche Fragestellung! (1 Punkt)
2. Formulieren Sie das statistische Hypothesenpaar! (1 Punkt)
3. Füllen Sie die unterstehende einfaktorielle ANOVA Ergebnistabelle aus! (3 Punkte)

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Bewässerungstypen	3	10.66			
Error	27	246.89			

4. Schätzen Sie den p-Wert der Tabelle mit $F_{\alpha=5\%} = 2.96$ ab. Begründen Sie Ihre Antwort! (2 Punkte)
5. Was bedeutet ein signifikantes Ergebnis in einer einfaktoriellen ANOVA? (1 Punkt)
6. Berechnen Sie *einen* Student t-Test für den *vermutlich* signifikantesten Gruppenvergleich anhand der untenstehenden Tabelle mit $T_{\alpha=5\%} = 2.03$. Begründen Sie Ihre Auswahl! (3 Punkte)

Bewässerungstypen	Fallzahl (n)	Mittelwert	Standardabweichung
ctrl	9	3.22	3.35
low	8	4.50	4.04
mid	6	3.67	2.25
high	8	3.00	1.60

7. Gegebenen der ANOVA Tabelle war das Ergebnis des Student t-Tests zu erwarten? Begründen Sie Ihre Antwort! (2 Punkte)

15 Aufgabe

(9 Punkte)

Geben Sie grundsätzlich Formeln und Rechenweg zur Lösung der Teilaufgaben mit an!

‘Mit dem R Paket {emmeans} können wir gleich die Gruppenvergleiche rechnen und uns das *compact letter displac*’ ausgeben lassen!’, verkündet Nilufar sichtlich stolz. Ein paar Mal hat sie schon die Erwartung gehindert weiterzumachen. ‘Nach Meinung des Betreuers soll es aber nur erstmal ein t-Test sein. Und die Ausgabe ist schon wirr genug.’, merkt Jonas an. Jonas und Yuki sind bei Nilufar um sich in R helfen zu lassen. Im Hintergrund wummert Deichkind. Yuki streichelt zur Beruhigung das Huhn von Nilufar. Die beiden waren 2 Monate im Wendland um einen Versuch mit Fleischrindern in einem Stallexperiment durchzuführen. Ziel war es das Outcome (Y) Gewichtszuwachs in der 1LW zu bestimmen. Nilufar überlegt, ob sie die beiden nicht noch auf den Film *Star Trek* einlädt oder dann doch lieber raus geht um zu Kicken? Vielleicht will ja Yuki mit. Besser als der Film.

```
##  
## Two Sample t-test  
##  
## data: Gewichtszuwachs by Flüssignahrung  
## t = 7.3637, df = 15, p-value = 2.353e-06  
## alternative hypothesis: true is not equal to [condensed]  
## 95 percent confidence interval:  
## 11.17488 20.27941  
## sample estimates:  
## mean in group ctrl mean in group fl0w  
## 41.55714 25.83000
```

Helfen Sie Nilufar bei der Interpretation des t-Tests! Sonst geht es auch für Jonas und Yuki nicht weiter.

1. Formulieren Sie die wissenschaftliche Fragestellung! **(1 Punkt)**
2. Formulieren Sie das statistische Hypothesenpaar! **(1 Punkt)**
3. Liegt ein signifikanter Unterschied zwischen den Gruppen vor? Begründen Sie Ihre Antwort! **(2 Punkte)**
4. Berechnen Sie den Effekt des t-Tests! **(1 Punkt)**
5. Skizzieren Sie die sich ergebenden Barplots! Begründen Sie Ihre Antwort! **(2 Punkte)**
6. Skizzieren Sie die sich ergebenden Boxplot! Welche Annahmen an die Daten haben Sie getroffen? Begründen Sie Ihre Antwort! **(2 Punkte)**

16 Aufgabe

(11 Punkte)

Geben Sie grundsätzlich Formeln und Rechenweg zur Lösung der Teilaufgaben mit an!

In ein Feldexperiment wurden Erbsen mit der Behandlung Lichtstufen (*none*, 200lm, 400lm und 600lm) sowie der Behandlung Genotypen (*AA*, und *BB*) untersucht. Es wurde als Messwert Proteingehalt [g/kg] bestimmt. Jetzt startet Mark mit auf die  Ausgabe einer zweifaktoriellen ANOVA. Leider starrt seine Betreuerin in der gleichen Art Mark zurück an. Es liegt anscheinend eine signifikante Interaktion vor? 'Das wird ein langer Nachmittag.', denkt er sich und kreuselt seinen Mund. 'Und was machen wir jetzt?' entfährt es ihm überrascht entnervt. Immerhin war geht es ja um seine Hausarbeit. Mark hätte doch nichts mit Erbsen machen sollen. Erbsen – was soll das auch bedeutendes sein? Eigentlich wollte Mark nachher noch einen Film schauen. Wenn Columbo läuft, dann ist der Hamster nicht mehr da. Aber jetzt braucht er mal Entspannung!

Leider kennen sich Mark und seine Betreuerin mit der zweifaktoriellen ANOVA überhaupt nicht aus. Geschweige denn mit der Interpretation einer Interaktion. Deshalb braucht er bei der Erstellung Ihre Hilfe, sonst wird es heute Abend mit seinem Hobby Geocaching nichts mehr!

1. Visualisieren Sie folgende mögliche Interaktionen zwischen den Behandlungen! Heben Sie die Positionen der auftretenden Interaktion (farblich) hervor! Beschriften Sie die Abbildung! **(4 Punkte)**
 - a) Keine Interaktion liegt vor.
 - b) Eine schwache Interaktion liegt vor.
 - c) Eine starke Interaktion liegt vor.
2. Erklären Sie den Unterschied zwischen den verschiedenen Interaktionen! **(2 Punkte)**
3. Welche statistische Maßzahl betrachten Sie für die Bewertung der Interaktion? **(1 Punkt)**
4. Schreiben Sie das Modell mit Interaktionsterm in  für eine zweifaktorielle ANOVA! **(1 Punkt)**
5. Skizzieren Sie die Funktion in  für eine Post-hoc Analyse in {emmeans}! **(1 Punkt)**
6. Wenn eine signifikante Interaktion in den Daten vorliegt, wie ist dann das weitere Vorgehen? Berücksichtigen Sie dabei die Verwendung von {emmeans}! **(2 Punkte)**

17 Hausarbeit

(10 Punkte)

Teil der Prüfungsleistung in dem Modul ist eine Hausarbeit zur Datenanalyse in R.

Diese Aufgabe dient in der Klausur als Platzhalter für die erreichten Punkte in der Hausarbeit.

Zum Bestehen des Moduls ist die Abgabe des Berichts nicht notwendig.

Alle Informationen zu der Hausarbeit sowie dem Stichtag der Abgabe finden Sie auf ILIAS.