

Name: _____

Nicht bestanden: ☐

Vorname: _____

Matrikelnummer: _____

Endnote: _____

Studierende der Fakultät Agrarwissenschaften und Landschaftsarchitektur (AuL)

Probeklausur Bio Data Science

für Pflichtmodule

im 1. & 2. Semester B.Sc./M.Sc.

Prüfer: Prof. Dr. Jochen Kruppa-Scheetz
Fakultät für Agrarwissenschaften und Landschaftsarchitektur
j.kruppa@hs-osnabrueck.de

Erlaubte Hilfsmittel

- Normaler Taschenrechner ohne Möglichkeit der Kommunikation mit anderen Geräten! Ausdrücklich kein Handy!
- Eine DIN A4-Seite als beidseitig, selbstgeschriebene, handschriftliche Formelsammlung. Keine digitalen Ausdrucke!
- *You can answer the questions in English without any consequences.*

Formalia

- Um eine faire Korrektur zu gewährleisten,
 - **ist die Verwendung eines roten Farbstiftes ist nicht gestattet. Es ist die Korrekturfarbe.**
 - schreiben Sie bitte groß genug und leserlich mit einem dokumentenechten Stift (kein Bleistift).
 - nicht zwischen die Fragezeilen schreiben! Die Nutzung des Aufgabentextes für Antworten führt zu Punktabzug.
 - erstellen Sie Abbildungen in angemessener Größe und achten Sie auf eine klare Erkennbarkeit. Nutzen Sie bei Platzmangel bitte ein separates Blatt.
- Verstöße können mit einem Punktabzug geahndet werden: **□ (-2 Punkte)**

Ergebnis der Klausur

_____ von 20 Punkten sind aus dem Multiple Choice Teil erreicht.
_____ von 72 Punkten sind aus dem Rechen- und Textteil erreicht.
_____ von 92 Punkten in Summe.

Es wird folgender Notenschlüssel angewendet.

Punkte	Note
88.0 - 92.0	1,0
83.5 - 87.5	1,3
78.5 - 83.0	1,7
74.0 - 78.0	2,0
69.5 - 73.5	2,3
65.0 - 69.0	2,7
60.5 - 64.5	3,0
55.5 - 60.0	3,3
51.0 - 55.0	3,7
46.0 - 50.5	4,0

Es ergibt sich eine Endnote von _____.

Multiple Choice Aufgaben

- Pro Multiple Choice Frage ist *genau* eine Antwort richtig.
- **Übertragen Sie Ihre Kreuze in die Tabelle auf dieser Seite.**
- Es werden nur Antworten berücksichtigt, die in dieser Tabelle angekreuzt sind!

	A	B	C	D	E	✓
1 Aufgabe						
2 Aufgabe						
3 Aufgabe						
4 Aufgabe						
5 Aufgabe						
6 Aufgabe						
7 Aufgabe						
8 Aufgabe						
9 Aufgabe						
10 Aufgabe						

- Es sind ____ von 20 Punkten erreicht worden.

Rechen- und Textaufgaben

- Die Tabelle wird vom Dozenten ausgefüllt.

Aufgabe	11	12	13	14	15	16	Hausarbeit
Punkte	8	10	10	12	10	12	10

- Es sind ____ von 72 Punkten erreicht worden.

1 Aufgabe

(2 Punkte)

Sie wollen nach einem Feldversuch die Standardabweichung berechnen. Welche der folgenden Rechenoperationen müssen durchgeführt werden?

- A ☐ Den Mittelwert berechnen, dann die quadratischen Abstände zum Mittelwert aufsummieren und durch die Fallzahl ($n - 1$) teilen.
- B ☐ Den Median berechnen, dann die quadratischen Abstände zum Median aufsummieren, dann die Wurzel ziehen. Am Ende durch die Fallzahl ($n - 1$) teilen
- C ☐ Den Mittelwert berechnen und die Abstände quadrieren. Die Summe mit der Fallzahl ($n - 1$) multiplizieren.
- D ☐ Als erstes berechnen wir den Mittelwert. Dann bilden wir die Summe der quadratischen Abstände zu dem Mittelwert. Abschließend subtrahieren wir die Fallzahl ($n - 1$).
- E ☐ Wir berechnen erst den Mittelwert und dann die quadratischen Abstände zu dem Mittelwert. Diese quadratischen Abstände summieren wir auf und teilen am Ende durch die Fallzahl ($n - 1$). Als letzten Schritt ziehen wir die quadratische Wurzel.

2 Aufgabe

(2 Punkte)

Sie führen einen agrarwissenschaftlichen Versuch durch. Dafür müssen Sie als ersten Schritt Ihre Versuchseinheiten zufällig den Behandlungen zuordnen. Dieses zufällige Zuordnen nennt man in der Statistik eine Randomisierung. Warum ist die Randomisierung so wichtig für das Gelingen eines Versuchs?

- A ☐ Randomisierung bringt starke Unstrukturiertheit in das Experiment und erlaubt erst von der Stichprobe auf die Grundgesamtheit zurückzuschliessen.
- B ☐ Randomisierung erlaubt erst die Mittelwerte zu schätzen. Ohne Randomisierung keine Mittelwerte. Ohne Mittelwerte keine Varianz und somit auch kein statistischer Test.
- C ☐ Strukturgleichheit ist durch Randomisierung gegeben. Leider hilft die Randomisierung noch nicht um von der Stichprobe auf die Grundgesamtheit zu schließen. Deshalb wurde das Falsifikationsprinzip entwickelt.
- D ☐ Randomisierung war bis 1952 bedeutend, wurde dann aber in Folge besserer Rechnerleistung nicht mehr verwendet. Aktuelle Statistik nutzt keine Randomisierung mehr.
- E ☐ Strukturgleichheit ist durch Randomisierung gegeben. Somit kann von der Stichprobe auf die Grundgesamtheit geschlossen werden

3 Aufgabe

(2 Punkte)

Nachdem Sie eine ANOVA und die paarweisen t-Tests über das  Paket {emmeans} durchgeführt haben, müssen Sie Ihre Daten nochmal zur Überprüfung visualisieren. Sie entscheiden sich für den Boxplot. Welche statistischen Maßzahlen stellt der Boxplot dar?

- A ☐ Durch die Abbildung des Boxplot erhalten wir die Informationen über den Median und die Quartile.
- B ☐ Der Boxplot stellt die Mittelwerte und die Standardabweichung dar.
- C ☐ Durch die Abbildung des Boxplot erhalten wir die Informationen über den Median und die Standardabweichung.
- D ☐ Den Mittelwert sowie den Median und die Streuung.
- E ☐ Den Mittelwert und die Varianz.

4 Aufgabe

(2 Punkte)

In Ihrer Abschlussarbeit rechnen Sie einen Student t-Test. Welche Aussage ist auch für den Welch t-Test richtig?

- A ☐ Der t-Test vergleicht die Mittelwerte von zwei Gruppen unter der strikten Annahme von Varianzhomogenität. Sollte keine Varianzhomogenität vorliegen, so gibt es keine Möglichkeit den t-Test in einer Variante anzuwenden.
- B ☐ Der t-Test vergleicht die Mittelwerte von zwei Gruppen.
- C ☐ Der t-Test berechnet die Differenz von zwei Mittelwerten als Effekt und gibt eine Entscheidung, ob sich die beiden Mittelwerte *jeweils* von Null unterscheiden.
- D ☐ Der t-Test testet generell zu einem erhöhten α -Niveau von 20%.
- E ☐ Der t-Test vergleicht die Varianzen von mindestens zwei oder mehr Gruppen

5 Aufgabe

(2 Punkte)

Das Signifikanzniveau α wird auch Fehler 1. Art genannt und liegt bei 5%. Warum wurde der Grenzwert von 5% als Signifikanzschwelle gewählt?

- A ☐ Der Begründer der modernen Statistik, R. Fischer, hat die Grenze simuliert und berechnet. Dadurch ergibt sich dieser optimale Cut-Off.
- B ☐ Im Rahmen eines langen Disputs zwischen Neyman und Fischer wurde $\alpha = 5\%$ festgelegt. Leider werden die Randbedingungen und Voraussetzungen an statistische Modelle heute immer wieder ignoriert.
- C ☐ Auf einer Statistikkonferenz in Genf im Jahre 1942 wurde dieser Cut-Off nach langen Diskussionen festgelegt. Bis heute ist der Cut Off aber umstritten, da wegen dem 2. Weltkrieg viele Wissenschaftler nicht teilnehmen konnten.
- D ☐ Die Festlegung von $\alpha = 5\%$ ist eine Kulturkonstante. Wissenschaftler benötigt eine Schwelle für eine statistische Testentscheidung, der Wert von α wurde aber historisch mehr zufällig gewählt.
- E ☐ Da Wissenschaftler eine Schwelle für die statistische Testentscheidung benötigen wurde α in einer großen Konferenz 1945 gewählt. Damit ist $\alpha = 5\%$ eine Kulturkonstante mit einem Rank einer Naturkonstante.

6 Aufgabe

(2 Punkte)

Aus einem Feldversuch ergibt sich die Notwendigkeit der Berechnung einer einfaktoriellen ANOVA. Es ergibt sich ein $\eta^2 = 0.52$. Welche Aussage ist richtig?

- A ☐ Die Berechnung von η^2 ist ein Wert für die Interaktion in der einfaktoriellen ANOVA.
- B ☐ Das η^2 beschreibt den Anteil der Varianz, der von den Behandlungsbedingungen erklärt wird.
- C ☐ Das η^2 beschreibt den Anteil der globalen Varianz, der von den Umweltbedingungen erklärt wird.
- D ☐ Der Anteil der Varianz, der von den Behandlungsbedingungen erklärt wird, wird durch das $1 - \eta^2$ beschrieben.
- E ☐ Das η^2 ist ein Wert für die Güte der ANOVA. Je kleiner desto besser. Ein η^2 von 0 bedeutet ein perfektes Modell mit keiner Abweichung. Die Varianz ist null.

7 Aufgabe

(2 Punkte)

Sie wollen eine Aussage über ein untersuchtes Individuum treffen. Dazu nutzen Sie einen statistischen Test. Können Sie eine valide Aussage aus einem statistischen Test erhalten?

- A ☐ Nein, wir können ein untersuchtes Individuum nicht mit einer ANOVA auswerten. Wir erhalten keine Aussage zum Individuum. Wir können aber den Test adjustieren und so die Auswertung ermöglichen.
- B ☐ Nein, wir erhalten nur eine Aussage zu zwei Individuen. Ein statistischer Test liefert Informationen zu einem Individuum im Vergleich zu einem anderen Individuum.
- C ☐ Ja, wir erhalten eine *einfache* Aussage. Wir müssen daher das Individuum im Kontext der Population adjustieren.
- D ☐ Nein, ein untersuchtes Individuum können wir mit einem statistischen Test nicht auswerten. Wir erhalten keine Aussage zum Individuum.
- E ☐ Ja, ein untersuchtes Individuum können wir mit einem statistischen Test auswerten. Wir erhalten dann eine Aussage zum Individuum.

8 Aufgabe

(2 Punkte)


Ein statistischer Test benötigt für die richtige Durchführung Hypothesen H , sonst ist der Test nicht zu interpretieren. Welche Aussage ist richtig?

- A ☐ Es gibt - bedingt durch das das Falsifikationsprinzip - ein Set von k Nullhypothesen, die iterative gegen $k - 1$ Alternativhypothesen getestet werden.
- B ☐ Es gibt ein statistisches Hypothesenpaar mit der Nullhypothese H_0 und der Alternativhypothese H_A oder H_1 .
- C ☐ Mit der Nullhypothese H_A und der Alternativhypothese H_0 gibt es zwei Hypothesen, die aber selten genutzt werden.
- D ☐ Es gibt ein statistisches Hypothesenpaar mit der Hypothese für und gegen die wissenschaftliche Fragestellung. Die Hypothesen werden H_{pro} und H_{contra} bezeichnet.
- E ☐ Ein statistisches Hypothesenpaare gibt es. Zum einen die Nullhypothese und zum anderen die Alternativhypothese. Es ist aber nur notwendig die Alternative anzugeben, da die Nullhypothese nicht beim Testen benötigt wird.

9 Aufgabe

(2 Punkte)

Im Folgenden sehen Sie ein Normalverteilung dargestellt. Welche Aussage zu der Normalverteilung und der Standardabweichung σ ist richtig?



- A ☐ Die Fläche unter der Kurve entspricht dem Signifikanzniveau α von 5%. Damit ist die Standardabweichung σ gleich 1 in der obigen Abbildung.
- B ☐ Die Fläche zwischen -2σ und 2σ ist 0.68 und 68% der Beobachtungen liegen somit zwischen $\bar{y} \pm \sigma$ in der obigen Verteilung.
- C ☐ Die Fläche rechts von 2σ ist der p-Wert mit $Pr(D|H_0)$ in der obigen Abbildung.
- D ☐ Die Fläche zwischen -2σ und 2σ ist 0.95 und 95% der Beobachtungen liegen somit zwischen $\bar{y} \pm 2\sigma$ in der obigen Verteilung.
- E ☐ Die Fläche unter der Kurve ist 1, wenn die Nullhypothese falsch ist. Wenn die Nullhypothese gilt, dann ist die Fläche $1 - \alpha$. Somit ergibt sich auch eine Standardabweichung σ mit α gleich 0.05 in beiden Fällen.

10 Aufgabe

(2 Punkte)

Welche Aussage zum mathematische Ausdruck $Pr(D|H_0)$ ist richtig?

- A** ☐ Die Wahrscheinlichkeit der Daten unter der Nullhypothese in der Grundgesamtheit.
- B** ☐ Die Wahrscheinlichkeit für die Nullhypothese, wenn die Daten wahr sind.
- C** ☐ Die Inverse der Wahrscheinlichkeit unter der die Nullhypothese nicht mehr die Alternativhypothese überdeckt.
- D** ☐ $Pr(D|H_0)$ ist die Wahrscheinlichkeit nicht die Daten D zu beobachten sondern die Nullhypothese, wenn diese wahr ist.
- E** ☐ $Pr(D|H_0)$ stellt die Wahrscheinlichkeit die Daten D und somit die Teststatistik T_D zu beobachten dar, wenn die Nullhypothese wahr ist.

11 Aufgabe

(8 Punkte)

Geben Sie grundsätzlich Formeln und Rechenweg zur Lösung der Teilaufgaben mit an!

Wenn die Wut nicht wäre, ja dann wäre wohl vieles möglich für Tina! Aber so.. Deshalb gilt anschauen, was andere vor einem gemacht haben. Für Tina ist es eine Möglichkeit schneller ans Ziel zu gelangen. Deshalb hat sich Tina viele Poster in der Fakultät angeschaut und ist zum Schluß gekommen, dass Barplots eine häufig genutzte Abbildung sind. Tina soll nun in ihrer Hausarbeit Brokoli untersuchen. Die Behandlung in ihrer Hausarbeit sind verschiedene Bewässerungstypen (*low*, *mid* und *high*). Erhoben wurden von Tina als Messwert (*Y*) *Ertrag* benannt als *yield* in ihrer Exceldatei. Erwartungsgemäß erhält sie von ihrem Betreuer den Auftrag die erhobenen Daten als Barplots darzustellen. Dann kann Tina auch schonmal abschätzen, was bei einem statistischen Test rauskommen könnte. Na dann mal los. Tina schafft sich die nötige Stimmung. Tina nickt im Takt von Tocotronic und bemerkt dabei gar nicht was die Spinne schon wieder anstellt.

treatment	yield
mid	28.1
low	18.5
low	22.3
mid	34.1
high	46.8
high	36.0
mid	38.9
high	39.8
mid	25.1
high	46.9
low	30.8

Leider kennt sich Tina mit der Erstellung von Barplots nicht aus. Deshalb braucht sie bei der Visualisierung Ihre Hilfe!

1. Formulieren Sie die wissenschaftliche Fragestellung! **(1 Punkt)**
2. Zeichnen Sie in einer Abbildung die Barplots für die Behandlung von Brokoli! Beschriften Sie die Achsen entsprechend! **(4 Punkte)**
3. Beschriften Sie einen Barplot mit den gängigen statistischen Maßzahlen! **(2 Punkte)**
4. Wenn Tina keinen Effekt zwischen den Behandlungen von Brokoli erwarten würde, wie sehen dann die Barplots aus? *Antworten Sie mit einer Skizze der Barplots!* **(1 Punkt)**

12 Aufgabe

(10 Punkte)

Geben Sie grundsätzlich Formeln und Rechenweg zur Lösung der Teilaufgaben mit an!

Jessica liest laut: 'Wenn zwei kontinuierliche Variablen vorliegen, können diese in einer explorativen Datenanalyse...'. Jessica stoppt. 'Hm...', Schokobons und David Bowie. Das ist und bleibt die beste Kombination zum Nachdenken für Jessica. Was waren noch gleich kontinuierliche Variablen? In ihrer Hausarbeit hatte sie ein Stallexperiment im Emsland durchgeführt. Dabei ging es um den Zusammenhang zwischen Schlachtgewicht [kg] und mittlerer Eisenkonzentration [Fe/ml] im groben Kontext von Zandern. Nun stellt sich die Frage für sie, ob es überhaupt einen Zusammenhang zwischen den gemessenen Variablen gibt. Dafür war eine explorative Datenanalyse gut! Wenn der Mangel nicht wäre, ja dann wäre wohl vieles möglich für Jessica! Aber so.. Dann was anderes. Das Verrückte ist, dass die Hündin Herr der Ringe wirklich liebt. Das ist Jessica sehr recht, denn sie braucht Entspannung.

Schlachtgewicht [kg]	Mittlerer Eisenkonzentration [Fe/ml]
6.0	13.6
0.5	4.0
7.0	9.3
0.0	2.0
10.5	14.7
5.0	8.2
5.5	8.4
2.5	7.3

Leider kennt sich Jessica mit der Erstellung einer explorativen Datenanalyse für kontinuierliche Daten überhaupt nicht aus. Deshalb braucht sie bei der Erstellung Ihre Hilfe!

1. Erstellen Sie eine Visualisierung für die Datentabelle. Beschriften Sie die Achsen entsprechend! **(4 Punkte)**
2. Schätzen Sie eine Grade durch die Punkte! **(1 Punkt)**
3. Beschriften Sie die Grade mit den gängigen statistischen Maßzahlen! Geben Sie die numerischen Zahlenwerte mit an! **(3 Punkte)**
4. Wenn *ein* Effekt von x auf y vorhanden wäre, wie würde die Grade verlaufen und welche Werte würden die statistischen Maßzahlen annehmen? **(2 Punkt)**

13 Aufgabe

(10 Punkte)

'Jetzt haben wir als Messwert *Wasserverbrauch der Bewässerung* erhoben und sind auch nicht weiter. Gut, wir haben alles zu einer Kontrolle vergleichen.', stellt Steffen fest. Paula schaut fragend in die Ferne. Die beiden haben ein Experiment für einen Mittelständler durchgeführt und überlegen jetzt, wie die Relevanz zusammen mit der Signifikanz in einem 95% Konfidenzintervall dargestellt werden kann. Jetzt haben beide das Problem, die möglichen 95% Konfidenzintervalle zu interpretieren.

Leider kennen sich Steffen und Paula mit der Visualisierung des 95% Konfidenzintervall überhaupt nicht aus.

1. Beschriften Sie die untenstehende Abbildung mit der Signifikanzschwelle! Begründen Sie Ihre Antwort! **(2 Punkte)**
2. Ergänzen Sie eine *in den Kontext passende* Relevanzschwelle! Begründen Sie Ihre Antwort! **(2 Punkte)**
3. Skizzieren Sie in die untenstehende Abbildung sechs einzelne Konfidenzintervalle (a-f) mit den jeweiligen Eigenschaften! **(6 Punkte)**
 - (a) Ein signifikantes, relevantes 90% Konfidenzintervall.
 - (b) Ein nicht signifikantes, nicht relevantes 95% Konfidenzintervall
 - (c) Ein 95% Konfidenzintervall mit niedriger Fallzahl n in der Stichprobe als der Rest 95% der Konfidenzintervalle
 - (d) Ein 95% Konfidenzintervall mit höherer Fallzahl n in der Stichprobe als der Rest der 95% Konfidenzintervalle
 - (e) Ein signifikantes, relevantes 95% Konfidenzintervall
 - (f) Ein signifikantes, nicht relevantes 95% Konfidenzintervall



14 Aufgabe

(12 Punkte)

Geben Sie grundsätzlich Formeln und Rechenweg zur Lösung der Teilaufgaben mit an!

Steffen und Paula schauen sich etwas entnervt an. Gemeinsam schreiben die beiden ihre Abschlussarbeit und sollen nun als erstes einmal die Daten mit einer einfaktoriellen ANOVA auswerten, damit abgeschätzt werden kann, ob überhaupt signifikante Ergebnisse in den multiplen Gruppenvergleichen zu erwarten sind. Deshalb erstmal Smarties mampfen, die Paula mitgebracht hat. Nun möchte erstmal ihre Betreuung der Arbeit eine ANOVA-Tabelle sehen. Was immer da auch drin zu erkennen sein mag. Steffen schaut Paula sehen erstmal gar nichts. Die beiden waren im Emsland um einen Leistungssteigerungsversuch mit Fleischrindern durchzuführen. Dabei haben Steffen und Paula den Messwert Fettgehalt [%/kg] unter der Behandlung Elterlinie (*ctrl*, *Standard*, *Yray* und *Xray*) ermittelt. Später wollen die beiden dann noch raus um zu Fechten.

Leider kennen sich Steffen und Paula mit Berechnung einer einfaktoriellen ANOVA überhaupt nicht aus. Deshalb brauchen beide bei der Erstellung Ihre Hilfe!

1. Formulieren Sie die wissenschaftliche Fragestellung! (1 Punkt)
2. Formulieren Sie das statistische Hypothesenpaar! (1 Punkt)
3. Füllen Sie die unterstehende einfaktorielle ANOVA-Ergebnistabelle aus! (3 Punkte)

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Elterlinie	3	9.78			
Error	26	100.92			

4. Schätzen Sie den p-Wert der Tabelle mit $F_{\alpha=5\%} = 2.98$ ab. Begründen Sie Ihre Antwort! (2 Punkte)
5. Was bedeutet ein signifikantes Ergebnis in einer einfaktoriellen ANOVA? (1 Punkt)
6. Berechnen Sie *einen* Student t-Test für den *vermutlich* signifikantesten Gruppenvergleich anhand der untenstehenden Tabelle mit $T_{\alpha=5\%} = 2.03$. Begründen Sie Ihre Auswahl! (3 Punkte)

Elterlinie	Fallzahl (n)	Mittelwert	Standardabweichung
ctrl	10	4.40	2.50
Standard	5	4.20	1.30
Yray	6	2.83	2.32
Xray	9	3.89	1.17

7. Gegebenen der ANOVA-Tabelle war das Ergebnis des Student t-Tests zu erwarten? Begründen Sie Ihre Antwort! (2 Punkte)

15 Aufgabe

(9 Punkte)

Geben Sie grundsätzlich Formeln und Rechenweg zur Lösung der Teilaufgaben mit an!

‘Mit dem R Paket {emmeans} können wir gleich die Gruppenvergleiche rechnen und uns das *compact letter displac*’ ausgeben lassen!’, verkündet Paula sichtlich stolz. Ein paar Mal hat sie schon der Perfektionismus gehindert weiterzumachen. ‘Nach Meinung der Betreuerin soll es aber nur erstmal ein t-Test sein. Und die Ausgabe ist schon wirr genug.’, merkt Tina an. Tina und Jessica sind bei Paula um sich in R helfen zu lassen. Im Hintergrund wummert White Lies. Jessica streichelt zur Beruhigung die Ratte von Paula. Die beiden waren 3 Monate im Wendland um einen Versuch mit Kartoffeln in einem Gewächshausexperiment durchzuführen. Ziel war es das Outcome (Y) Proteingehalt [g/kg] zu bestimmen. Paula überlegt, ob sie die beiden nicht noch auf den Film *Jagd auf roter Oktober* einlädt oder dann doch lieber raus geht um zu Fechten? Vielleicht will ja Jessica mit. Besser als der Film.

```
##
## Two Sample t-test
##
## data: Proteingehalt by Substrattypen
## t = -0.053653, df = 15, p-value = 0.9579
## alternative hypothesis: true is not equal to [condensed]
## 95 percent confidence interval:
## -9.483550 9.017836
## sample estimates:
## mean in group torf mean in group 70p30n
## 34.61000 34.84286
```

Helfen Sie Paula bei der Interpretation des t-Tests! Sonst geht es auch für Tina und Jessica nicht weiter.

1. Formulieren Sie die wissenschaftliche Fragestellung! **(1 Punkt)**
2. Formulieren Sie das statistische Hypothesenpaar! **(1 Punkt)**
3. Liegt ein signifikanter Unterschied zwischen den Gruppen vor? Begründen Sie Ihre Antwort! **(2 Punkte)**
4. Berechnen Sie den Effekt des t-Tests! **(1 Punkt)**
5. Skizzieren Sie die sich ergebenden Barplots! Begründen Sie Ihre Antwort! **(2 Punkte)**
6. Skizzieren Sie die sich ergebenden Boxplot! Welche Annahmen an die Daten haben Sie getroffen? Begründen Sie Ihre Antwort! **(2 Punkte)**

16 Aufgabe

(11 Punkte)

Geben Sie grundsätzlich Formeln und Rechenweg zur Lösung der Teilaufgaben mit an!

Es ist schon kurz nach fünf und Nilufar wird langsam nervös. Nilufar wollte heute Abend noch ihre E-Sport Qualifikation schauen und dann zum Sport. Stattdessen versucht ihre Betreuerin die Ausgabe der zweifaktoriellen ANOVA zu visualisieren und zu überprüfen, ob es mit der Visualisierung der Daten als Boxplots zusammenpasst. Es liegt anscheinend eine signifikante Interaktion vor? Nilufar hatte im Wendland ein Kreuzungsexperiment mit Hühnern durchgeführt. Es gab dabei zwei Behandlungen. Einmal Lüftungssystem (*keins*, *storm*, *tornado* und *thunder*) sowie als zweite Behandlung Flüssignahrung (*ctrl* und *flOw*). Gemessen wurde der Messwert (*Y*) Protein/Fettrate [%/kg]. So kompliziert kann das jetzt doch nicht sein! Eigentlich wollte Nilufar nachher noch zum Sport. Nilufar will später nochmal raus um zu Kicken. Druck ablassen, dass muss sie auch.

Leider kennen sich Nilufar und ihre Betreuerin mit der zweifaktoriellen ANOVA überhaupt nicht aus. Geschweige denn mit der Interpretation einer Interaktion. Deshalb braucht sie bei der Erstellung Ihre Hilfe, sonst wird es heute Abend mit seinem Hobby Hip Hop nichts mehr!

1. Visualisieren Sie folgende mögliche Interaktionen zwischen den Behandlungen! Heben Sie die Positionen der auftretenden Interaktion (farblich) hervor! Beschriften Sie die Abbildung! **(4 Punkte)**
 - a) Keine Interaktion liegt vor.
 - b) Eine schwache Interaktion liegt vor.
 - c) Eine starke Interaktion liegt vor.
2. Erklären Sie den Unterschied zwischen den verschiedenen Interaktionen! **(2 Punkte)**
3. Welche statistische Maßzahl betrachten Sie für die Bewertung der Interaktion? **(1 Punkt)**
4. Schreiben Sie das Modell mit Interaktionsterm in  für eine zweifaktorielle ANOVA! **(1 Punkt)**
5. Skizzieren Sie die Funktion in  für eine Post-hoc Analyse in {emmeans}! **(1 Punkt)**
6. Wenn eine signifikante Interaktion in den Daten vorliegt, wie ist dann das weitere Vorgehen? Berücksichtigen Sie dabei die Verwendung von {emmeans}! **(2 Punkte)**

17 Hausarbeit

(10 Punkte)

Teil der Prüfungsleistung in dem Modul ist eine Hausarbeit zur Datenanalyse in R.

Diese Aufgabe dient in der Klausur als Platzhalter für die erreichten Punkte in der Hausarbeit.

Zum Bestehen des Moduls ist die Abgabe des Berichts nicht notwendig.

Alle Informationen zu der Hausarbeit sowie dem Stichtag der Abgabe finden Sie auf ILIAS.